

Escuela Técnica Superior de Ingeniería Universidad de Huelva

Grado en Ingeniería Informática

Trabajo Fin de Grado

Modelos de Inteligencia Artificial para la
detección y diagnóstico precoz de
enfermedades neurodegenerativas
mediante el estudio de la voz.

Autor: Jesús David Calvente Zapata

Tutor: Francisco Alfredo Márquez Hernández

Junio 2026

Trabajo Fin de Grado.

Grado en Ingeniería Informática.

Título: Modelos de Inteligencia Artificial para la detección y diagnóstico precoz de enfermedades neurodegenerativas mediante el estudio de la voz.

Autor: Jesús David Calvente Zapata.

Tutor: Francisco Alfredo Márquez Hernández.

Departamento de Tecnologías de la Información.

Escuela Técnica Superior de Ingeniería.

Universidad de Huelva.

Resumen

(resumen)

Palabras clave: (Palabras Claves)

Abstract

(abstract)

Keywords: (keywords)

Agradecimientos

(agradecimientos)

Índice general

Índice de figuras

Índice de cuadros

Introducción a la propuesta

1.1. Contexto y motivación: Relevancia de la detección precoz en enfermedades neurodegenerativas

Este proyecto nace de la necesidad de abordar uno de los principales desafíos que enfrenta la medicina moderna: lograr un diagnóstico temprano, no invasivo, accesible y de bajo coste para patologías altamente prevalentes y con un profundo impacto en la calidad de vida de los pacientes. En particular, este trabajo se focaliza en las enfermedades neurodegenerativas, afecciones cuya incidencia se encuentra en continuo aumento debido al envejecimiento demográfico de la población mundial. Estas patologías se caracterizan por la pérdida progresiva de la función neuronal, conduciendo en la gran mayoría de los casos a un severo deterioro cognitivo, así como a una drástica disminución de la funcionalidad y de la independencia personal.

La detección precoz de estas alteraciones es crucial, ya que permite una intervención temprana y la implementación de estrategias de manejo clínico que pueden ralentizar la progresión de la enfermedad, mejorar el bienestar del paciente y brindar apoyo a su entorno familiar (?, ?).

Sin embargo, los métodos de diagnóstico actuales presentan barreras de accesibilidad significativas. Técnicas como la resonancia magnética o el análisis de líquido cefalorraquídeo, si bien son clínicamente efectivas, resultan invasivas y requieren de infraestructuras complejas y personal altamente especializado. Esta dependencia de recursos clínicos avanzados genera limitaciones de disponibilidad geográfica, provocando que el acceso a un diagnóstico temprano sea desigual y dependa de la capacidad de la red sanitaria territorial (?, ?).

En este contexto, surge la necesidad de desarrollar herramientas de cribado alternativas. Este trabajo propone explorar el potencial de la Inteligencia Artificial y el análisis de datos para identificar patrones sutiles en la voz de los pacientes, tales como indicadores de disfonía, inestabilidad en la fonación o temblor neuromotor. Estas anomalías vocales podrían actuar como biomarcadores digitales indicativos de la presencia de enfermedades neurodegenerativas en sus fases iniciales. La fonación requiere una coordinación neuromuscular extremadamente precisa, convirtiendo a la voz en una fuente rica en información y en un candidato altamente prometedor para el diagnóstico temprano (?, ?).

Por consiguiente, la motivación central de este proyecto es aportar una solución tecnológica orientada a la democratización del prediagnóstico. El objetivo último es desarrollar y validar un sistema computacional que, analizando la voz como biomarcador, actúe como sistema de apoyo a la decisión clínica, ofreciendo a los pacientes una vía accesible para la identificación precoz de estas patologías.

1.2. Objetivos del proyecto

1.2.1. Objetivo general

El objetivo general de este proyecto consiste en diseñar, desarrollar y evaluar un sistema de inteligencia artificial capaz de detectar de forma precoz enfermedades neurodegenerativas a través del análisis de la voz de los pacientes. Este sistema buscará identificar patrones sutiles en las características vocales que puedan estar asociados con la presencia de estas patologías, con el fin de proporcionar una herramienta clínica no invasiva, accesible y de bajo coste para su detección.

1.2.2. Objetivos específicos

Para alcanzar el objetivo general, se han definido los siguientes objetivos específicos que guiarán el desarrollo del proyecto:

- Recopilar información y datos relevantes sobre las características vocales asociadas con enfermedades neurodegenerativas mediante una revisión exhaustiva de la literatura científica, e identificar los modelos de inteligencia artificial más adecuados para el análisis de este tipo de datos
- Diseñar y desarrollar un sistema de inteligencia artificial que implemente técnicas de aprendizaje automático para analizar las características vocales extraídas de los pacientes.
- Evaluar el rendimiento del sistema desarrollado utilizando conjuntos de datos de voz de pacientes diagnosticados y de controles sanos, con el fin de determinar su precisión, sensibilidad y especificidad en la fase temprana de la enfermedad.
- Analizar los resultados obtenidos y comparar el rendimiento del sistema propuesto con los métodos de diagnóstico clínico tradicionales, evaluando así su viabilidad como herramienta complementaria.
- Desarrollar una aplicación o interfaz de usuario que permita a los profesionales de la salud interactuar con el sistema de inteligencia artificial de manera intuitiva, sencilla y efectiva en su práctica clínica diaria.

1.3. Estructura de la memoria

Dejando de lado esta introducción, la memoria se organiza en los siguientes capítulos:

- En el ??, se presenta el Estado del Arte y el marco teórico que fundamenta este proyecto. Se comienza con una contextualización clínica de las enfermedades neurodegenerativas con mayor prevalencia, haciendo especial hincapié en el Parkinson, la Esclerosis Lateral Amiotrófica (ELA) y el Alzheimer. A continuación, se introduce el uso de la voz como biomarcador y se detalla el flujo de trabajo técnico necesario para su análisis, incluyendo el preprocesamiento de audio y la extracción de características acústicas. Posteriormente, se realiza una revisión exhaustiva y una comparativa de los modelos de Inteligencia Artificial más empleados en la literatura para este fin, analizando sus ventajas e inconvenientes. El capítulo finaliza con una exploración de las tendencias futuras en este ámbito y unas breves conclusiones que justifican las decisiones técnicas adoptadas en el presente trabajo.
- En el ??, se realiza un recorrido por los distintos recursos que se usan en este proyecto, comenzando por los datasets usados y el entorno de trabajo en el que se ha desarrollado este. Por otro lado se hará hincapié en el pipeline de Preprocesado que recorrerán todos los audios involucrados en el entreno, la validación y aquellos que se analicen durante la fase de producción. Por último se hablará de las métricas que dictaminarán la excelencia de los modelos obtenidos.
- En el ??, se profundizará en el diseño de cada uno de los modelos, empezando por las configuraciones experimentales y estrategias de entreno, tales como optimización de hiperparámetros o uso de validación cruzada, abordándolo primeramente de una forma general y profundizando en cada uno de los apartados hasta llegar a la configuración final de los modelos obtenidos.
- En el ??, se realizará un seguimiento de la aplicación desarrollada para hacer uso de los modelos, profundizaremos en la arquitectura elegida explicando los roles que desempeñan cada uno de los actores que intervienen, por otro lado, también se analizará el tratamiento de los datos y su flujo a lo largo de la predicción. Por último se expondrá el despliegue de la aplicación y como se ve su interfaz.
- En el ??, se analizarán los rendimientos de los modelos comparándolos entre sí bajo distintos criterios como pueden ser la arquitectura propia, la interpretabilidad o el propio rendimiento de estos, finalizando con una comparativa global que supondrá un resumen de este.
- En el ??, se expondrán las conclusiones finales indagando y profundizando en las limitaciones que presenta cada uno de los modelos y presentándose cuales serían las posibles mejoras y cual sería el camino a seguir en esta investigación.

Además se han incluido X anexos que apoyan el contenido principal de este Trabajo Fin de Grado.

- En el **Anexo I**,

- En el **Anexo II**,

Capítulo 2

Estado del arte

2.1. Introducción

Las enfermedades neurodegenerativas representan uno de los mayores desafíos clínicos contemporáneos debido a su profundo impacto socioeconómico y a su progresión clínica irreversible. Patologías como la enfermedad de Parkinson, la enfermedad de Alzheimer o la Esclerosis Lateral Amiotrófica (ELA) comprometen severamente a una vasta proporción de la población mundial. El deterioro de las funciones motoras, cognitivas y del lenguaje se produce de forma gradual. Por consiguiente, la detección precoz se ha consolidado como un factor clínico determinante. La intervención temprana permite implementar estrategias terapéuticas más eficaces, ralentizar el declive funcional y optimizar la calidad de vida del paciente. Sin embargo, los protocolos diagnósticos tradicionales, fundamentados en evaluaciones neuropsicológicas o pruebas de neuroimagen, presentan limitaciones sustanciales. Con frecuencia, estas metodologías resultan invasivas, implican altos costes económicos y carecen de la sensibilidad necesaria para identificar alteraciones estructurales o funcionales en fases iniciales.

Como respuesta a estas limitaciones, el análisis computacional de la voz ha emergido recientemente como una alternativa diagnóstica altamente prometedora para la identificación temprana de anomalías neurológicas. La fonación constituye un proceso fisiológico complejo que exige la sincronización precisa de los subsistemas respiratorio, fonatorio, articulatorio y cognitivo. Consecuentemente, el daño tisular o la alteración neuromotora en el sistema nervioso central se proyecta directamente sobre las emisiones vocales. Estas deficiencias inducen modificaciones sutiles en los patrones acústicos y prosódicos del individuo. Aunque dichas variaciones resultan habitualmente imperceptibles para el sistema auditivo humano, pueden ser parametrizadas mediante la extracción de características acústicas específicas, como la perturbación de la frecuencia (jitter), la perturbación de la amplitud (shimmer) o los coeficientes cepstrales en las frecuencias de Mel (MFCC). De este modo, la señal de voz adquiere la categoría de biomarcador digital. Su naturaleza intrínsecamente no invasiva, junto con su alta accesibilidad y bajo coste, sitúan a esta modalidad como un instrumento idóneo para el cribado poblacional y la monitorización del deterioro neurocognitivo.

De forma simultánea, la irrupción de la Inteligencia Artificial (IA) y el desarrollo de arquitecturas de aprendizaje automático y profundo han redefinido el procesamiento de señales biomédicas. La aplicación de estos algoritmos a la acústica médica ha posibilitado la creación de modelos predictivos capaces de clasificar con alta precisión entre fonaciones patológicas y sujetos de control. Se han

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre
impacto
epide-
mioló-
gico y
econó-
mico de
enfer-
medades
neurode-
generati-
vas]

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre la
fisiolo-
gía de la
voz y su
relación
con alte-
raciones
neuro-
motoras]

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre la
fisiolo-
gía de la
voz y su
relación
con alte-
raciones
neuro-
motoras]

alcanzado métricas de rendimiento diagnóstico que rivalizan o incluso superan a las obtenidas mediante la instrumentación clínica estándar. Históricamente, se han implementado algoritmos clásicos de aprendizaje supervisado, tales como Máquinas de Vectores de Soporte (SVM) y Bosques Aleatorios (RF), para la clasificación de vectores de características extraídos manualmente. Posteriormente, la transición hacia el aprendizaje profundo ha favorecido la integración de Redes Neuronales Convolucionales (CNN) y Redes de Memoria a Corto y Largo Plazo (LSTM) para la extracción automática de patrones espaciotemporales directamente desde los espectrogramas o la forma de onda temporal. En la actualidad, el paradigma experimenta una transición hacia el uso de modelos fundacionales y técnicas de aprendizaje autosupervisado. Arquitecturas preentrenadas sobre corpus acústicos masivos no etiquetados, como wav2vec 2.0 o data2vec, se están adaptando mediante un proceso de ajuste fino para capturar representaciones latentes del habla con una capacidad de generalización superior en tareas de diagnóstico patológico .

Bajo esta premisa, la presente revisión del Estado del Arte persigue analizar y sintetizar la literatura científica más relevante en torno a la aplicación de la Inteligencia Artificial al estudio de la voz para la detección y el diagnóstico temprano de enfermedades neurodegenerativas. A lo largo del documento, se examinarán de forma sistemática los enfoques metodológicos predominantes y las métricas de desempeño reportadas en investigaciones contemporáneas. Asimismo, se identificarán las limitaciones técnicas actuales y se trazarán las líneas de investigación futuras. Toda la información consolidada en esta sección proporcionará el sustento teórico y metodológico necesario para el posterior diseño, entrenamiento y evaluación de los modelos experimentales planteados en este Trabajo de Fin de Grado.

2.2. Enfermedades neurodegenerativas. Visión general

Las enfermedades neurodegenerativas engloban un conjunto de trastornos definidos por la degradación progresiva del sistema nervioso central. Esta condición clínica induce un deterioro gradual e irreversible de las capacidades motoras, cognitivas y lingüísticas del paciente. Aunque cada entidad nosológica exhibe un fenotipo clínico particular, se reconocen mecanismos causales compartidos. Se ha documentado la presencia de agregación proteica anómala, estrés oxidativo, neuroinflamación sostenida y apoptosis neuronal selectiva en regiones encefálicas específicas . En la actualidad, este conjunto de patologías representa una causa primaria de discapacidad en la población geriátrica. Se prevé un incremento exponencial de su prevalencia como consecuencia directa del envejecimiento demográfico global. Dentro de este espectro clínico, la enfermedad de Parkinson, la enfermedad de Alzheimer y la Esclerosis Lateral Amiotrófica presentan un interés investigativo prioritario para el análisis acústico biomédico.

Entre las más relevantes, desde el punto de vista del análisis de la voz, se encuentran la enfermedad de Parkinson, la enfermedad de Alzheimer y la Esclerosis Lateral Amiotrófica (ELA).

La enfermedad de Parkinson (EP) se define como una patología crónica originada por la degene-

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre
modelos
founda-
tion en
análisis
de voz
patológi-
ca]

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre
meca-
nismos
fisiopa-
tológicos
comunes
en neu-
rodege-
neración]

ración de las neuronas dopaminérgicas ubicadas en la sustancia negra mesencefálica. Clásicamente, se diagnostica a través de manifestaciones del sistema motor como el temblor en reposo, la bradicinesia (lentitud de movimiento) o la rigidez articular. Adicionalmente, los pacientes desarrollan con alta frecuencia una sintomatología fonatoria específica. Se registra habitualmente hipofonía, pérdida de modulación frecuencial, imprecisión articulatoria y un déficit notable en el control del soporte respiratorio. Estas disfunciones del aparato fonador generan alteraciones cuantificables en la señal de voz. Frecuentemente, estas anomalías se manifiestan en estadios subclínicos y preceden a la sintomatología motora convencional. Por tanto, el procesamiento digital del habla se posiciona como una técnica notablemente sensible para la detección temprana de esta patología.

Por otra parte, la enfermedad de Alzheimer (EA) constituye el subtipo de demencia con mayor incidencia epidemiológica. Se caracteriza por un declive progresivo de las funciones cognitivas superiores, afectando primariamente a la memoria episódica, la atención y el lenguaje. Las alteraciones comunicativas asociadas a esta demencia exhiben una naturaleza fundamentalmente lingüística y prosódica. Se observa un incremento en la duración y recurrencia de las pausas silenciosas, una pérdida de afluencia discursiva, restricción del acervo léxico, simplificación sintáctica y un aplanamiento de la curva entonativa. Estas modificaciones deterioran tanto la estructura acústica de la emisión como la organización semántica del discurso espontáneo. La extracción de estas variables permite obtener inferencias clínicas precisas sobre el estado neurológico del individuo.

Respecto a la Esclerosis Lateral Amiotrófica (ELA), esta enfermedad provoca la degeneración progresiva de las neuronas motoras. El cuadro clínico deriva en una debilidad muscular incapacitante y en la pérdida absoluta del control voluntario. Cuando la degeneración compromete inicialmente la región bulbar, se ven afectados de forma directa los grupos musculares implicados en la respiración, la fonación y la articulación. Se manifiesta clínicamente mediante disartria, inestabilidad en la intensidad fonatoria, alteraciones marcadas en la tasa de expresión y fatiga respiratoria prematura. La evaluación de parámetros acústicos facilita la identificación prematura del daño neuromuscular. Esto favorece un diagnóstico acelerado de la variante bulbar y habilita una monitorización de la progresión de la enfermedad.

La práctica clínica habitual fundamenta el diagnóstico de estas patologías neurológicas en la aplicación de baterías neuropsicológicas y la realización de pruebas de neuroimagen. Si bien estas metodologías convencionales poseen validez clínica, presentan restricciones significativas. Se requiere infraestructura especializada, suponen un coste económico elevado y, habitualmente, carecen de la sensibilidad necesaria para identificar alteraciones en fases iniciales. Ante este escenario, el modelado computacional de la voz mediante arquitecturas de Inteligencia Artificial se propone como un sistema complementario de alto impacto. Se ofrece una alternativa metodológica objetiva, accesible, carente de invasividad y con una alta capacidad de escalabilidad poblacional. Únicamente a través de la comprensión profunda de estas manifestaciones vocales se puede acometer el diseño y entrenamiento de modelos predictivos eficaces para el diagnóstico diagnóstico y seguimiento clínico.

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre di-
sartria
hipoci-
nética en
la enfer-
medad
de Par-
kinson]

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre
perfiles
del len-
guaje y
habla
en la
enferme-
dad de
Alzhei-
mer]

[CITA
PEN-
DIEN-
TE: bus-
car ref
sobre
caracte-
rísticas
vocales
en ELA
de inicio
bulbar]

2.3. La voz como biomarcador. Fundamentos

La voz humana es un proceso complejo que involucra la coordinación de múltiples sistemas fisiológicos: respiratorio, fonatorio, articulatorio y resonante, además del control motor y cognitivo necesario para el habla. Cualquier alteración en estos mecanismos, especialmente aquellas provocadas por enfermedades que afectan al sistema nervioso central, puede generar cambios sutiles pero medibles. Por ello, la voz se considera un biomarcador potencial para el estudio y la detección temprana de diversas patologías neurodegenerativas.

En las últimas décadas, varios estudios han demostrado que las alteraciones en la voz pueden revelar signos tempranos de enfermedades como Parkinson, Alzheimer o ELA incluso antes de que se manifiesten síntomas clínicos evidentes. En la enfermedad de Parkinson, por ejemplo, la pérdida de control muscular y la rigidez afectan a la fonación y la articulación, generando disminución del tono (hipofonía), monotonía prosódica y aumento de la variabilidad del jitter y shimmer. En el Alzheimer, las alteraciones derivadas del deterioro cognitivo se reflejan en pausas más frecuentes, reducción de la fluidez verbal, menor variabilidad melódica y cambios en la duración de los fonemas. En el caso de la ELA, la debilidad de los músculos bulbares produce disartria, nasalización y pérdida del control de la intensidad. Todas ellas cuantificables con análisis acústico.

La principal ventaja de la voz como biomarcador radica en su naturaleza no invasiva y económica: las grabaciones de voz pueden obtenerse fácilmente con un micrófono convencional o incluso con los dispositivos móviles que nos acompañan en nuestro día a día, sin necesidad de equipamiento médico especializado. Además, su análisis puede automatizarse completamente mediante algoritmos de procesamiento digital de señales e inteligencia artificial, permitiendo un cribado masivo y continuo, algo impensable con los métodos clínicos tradicionales.

Los estudios sobre análisis de voz en el ámbito médico suelen utilizar distintos tipos de tareas vocales, diseñadas para resaltar diferentes aspectos del control motor y cognitivo del habla:

- **Vocales sostenidas** por ejemplo, la fonación prolongada del sonido /a/, permiten analizar la estabilidad de la frecuencia fundamental, la amplitud y la calidad vocal.
- **Lectura o repetición de frases controladas**, útiles para medir la articulación, la prosodia y la coordinación respiratoria.
- **Discurso espontáneo**, facilitan la evaluación de parámetros más complejos tales como la fluidez, la entonación, las pausas y la coherencia lingüística.

Cada una de estas tareas proporciona información complementaria, y su elección depende del objetivo del estudio y del tipo de enfermedad a analizar.

Desde un punto de vista más técnico, los biomarcadores vocales se extraen a partir de las señales

acústicas utilizando herramientas como openSMILE, librosa o Praat, que permiten calcular centenares de características relacionadas con la frecuencia, la energía, el espectro y la prosodia. Estos parámetros pueden posteriormente integrarse en modelos de aprendizaje automático o profundo, con el fin de establecer relaciones entre las características vocales.

En síntesis, la voz constituye una fuente rica de información, capaz de reflejar alteraciones neuromotoras y cognitivas con gran sensibilidad. Su combinación con las técnicas de inteligencia artificial abre una puerta hacia la creación de sistemas de diagnóstico precoz objetivos, accesibles y escalables, capaces de detectar signos tempranos de enfermedades neurodegenerativas a partir de simples grabaciones de voz.

2.4. Extracción de características vocales

El análisis de la voz mediante técnicas de Inteligencia Artificial requiere, como paso previo fundamental, la extracción de características que representen de forma cuantitativa las propiedades acústicas, prosódicas y articulatorias del habla. Estas características constituyen la base sobre la que los modelos de aprendizaje podrán identificar patrones asociados a las distintas enfermedades. La calidad, diversidad y relevancia de las características seleccionadas tienen un impacto directo en el rendimiento de los modelos.

Las características vocales se agrupan habitualmente en varias categorías, cada una de las cuales refleja un aspecto concreto del proceso de producción del habla.

2.4.1. Características acústicas

Son las más utilizadas y se derivan directamente de la señal de audio. Entre ellas destacan los Coeficientes Cepstrales en Frecuencia Mel (MFCCs), que representan la envolvente espectral del sonido y modelan la percepción auditiva humana. Los MFCCs han demostrado ser altamente discriminativos en la detección de la enfermedad de Parkinson y de Alzheimer, ya que capturan alteraciones sutiles en la fonación y en la articulación. Otros parámetros acústicos relevantes incluyen:

- **Jitter**(variación de frecuencia) y **Shimmer** (variación de amplitud) que indican inestabilidad vocal.
- **Relación Armónico-Ruido (HNR)** que mide la calidad de la voz y la presencia de turbulencias.
- **Formantes (F1–F3)** que reflejan la configuración articulatoria del tracto vocal y suelen alterarse en patologías motoras.

Estos parámetros pueden obtenerse fácilmente mediante herramientas como Praat u openSMILE, y suelen normalizarse para reducir la variabilidad entre hablantes.

2.4.2. Características prosódicas

Las features prosódicas describen el patrón rítmico y entonación del habla, e incluyen medidas de frecuencia fundamental (F0), duración de sílabas y pausas y variabilidad de la intensidad. En enfermedades como el Alzheimer, donde se altera la planificación del discurso, o en Parkinson, donde la prosodia tiende a ser monótona, estos parámetros son especialmente informativos. La combinación de medidas temporales y entonativas permite distinguir entre cambios motores y cognitivos en el control del habla.

2.4.3. Características articulatorias y paralingüísticas

Estas características describen aspectos relacionados con la precisión fonética, la fluidez y la coordinación motora del habla. Por ejemplo, la velocidad de articulación, la coherencia entre sílabas o la estabilidad respiratoria pueden diferenciar sujetos con ELA. Por otra parte, los descriptores paralingüísticos, capturan información emocional o de estilo de habla que también puede alterarse con la enfermedad. Con el estándar ComParE (Computational Paralinguistics Challenge), implementado en openSMILE, se incluyen cientos de parámetros para aplicaciones biomédicas, convirtiéndolo en una herramienta útil en estudios de Parkinson y Alzheimer.

2.4.4. Representaciones espectrales y de alto nivel

El desarrollo del aprendizaje profundo ha impulsado el uso de representaciones espectrales como mel-spectrogramas o espectrogramas logarítmicos entre otros, que se utilizan como entrada para modelos de redes neuronales convolucionales (CNN). Estos mapas tiempo-frecuencia permiten que los modelos aprendan patrones característicos de cada patología, eliminando la necesidad de ingeniería manual de características. Estudios recientes, como los de Worasawate et al. (2021) y Álvarez Marquina et al. (2022), han demostrado que el uso de espectrogramas combinados con CNN puede alcanzar precisiones superiores al 95 % en la clasificación de pacientes con Parkinson.

2.4.5. Embeddings y representaciones profundas

Más recientemente, se han introducido representaciones de alto nivel denominadas embeddings, generadas por modelos preentrenados en grandes corpus de voz. Entre las más utilizadas destacan los i-vectors y x-vectors, empleados por Moro-Velázquez et al. (2020, 2021), que resumen la información del

hablante en un espacio de baja dimensión y permiten capturar rasgos relacionados con la articulación, la prosodia y la fonación. Así mismo, los denominados foundation models, como wav2vec2.0, data2vec o Whisper, han revolucionado el campo al aprender representaciones auto-supervisadas del habla sin necesidad de etiquetas. Estos modelos, explorados en trabajos como Agbavor & Liang (2022) y Dao et al. (2025), proporcionan características de alto nivel que mejoran la generalización y reducen el tiempo de preprocesado.

2.4.6. Herramientas y procesos de preprocesamiento

El pipeline habitual para la extracción de características incluye:

1. **Adquisición de la señal** mediante grabaciones de voz controladas o espontáneas.
2. **Preprocesamiento** eliminando el ruido, normalizando el volumen, segmentando temporalmente y detectando silencios.
3. **Extracción de características** con la ayuda de librerías como librosa, openSMILE o Praat.
4. **Selección de características** mediante análisis estadístico o técnicas automáticas (ANOVA, PCA, Recursive Feature Elimination).

La elección de las características depende del tipo de modelo empleado y de la enfermedad objetivo. Por ejemplo, los modelos clásicos como Support Vector Machines (SVM) suelen requerir un conjunto limitado de features bien definidas, mientras que las redes profundas pueden operar directamente sobre espectrogramas o embeddings sin una selección previa.

En resumen, la etapa de extracción de características constituye un componente esencial en los sistemas de análisis de voz para la detección de enfermedades neurodegenerativas. La integración de features acústicas, prosódicas y profundas proporciona una representación completa del habla, capaz de reflejar tanto alteraciones motoras como cognitivas. En las secciones siguientes se abordarán los distintos enfoques de modelado con Inteligencia Artificial, analizando cómo cada tipo de algoritmo utiliza estas características para clasificar o predecir la presencia de enfermedad.

2.5. Modelos de Inteligencia Artificial aplicados al análisis de voz

La aplicación de modelos de Inteligencia Artificial (IA) al análisis de la voz permite desarrollar sistemas capaces de detectar patrones acústicos y prosódicos asociados a enfermedades neurodegenerativas. Estos modelos se entrenan con características vocales previamente extraídas o directamente con representaciones espectrales de la señal, con el fin de clasificar a los individuos según su estado

neurológico. En las investigaciones consultadas sobre el tema, los enfoques pueden agruparse en cuatro categorías principales: métodos clásicos de aprendizaje automático, modelos de aprendizaje profundo, modelos basados en embeddings o foundation models y enfoques de inteligencia artificial explicable (XAI).

2.5.1. Métodos clásicos de aprendizaje automático

Los modelos clásicos de Machine Learning (ML) se han utilizado extensamente en la detección de Parkinson, Alzheimer y ELA debido a su facilidad de interpretabilidad, bajo coste computacional y eficacia en datasets con pocos datos. Entre los algoritmos más empleados destacan: Support Vector Machine (SVM), Random Forest (RF), K-Nearest Neighbors (KNN), Logistic Regression y AdaBoost, que operan sobre conjuntos de features previamente seleccionadas.

En el ámbito del Parkinson, Tougui et al. (2020) emplea un sistema de clasificación usando SVM, KNN, RF y Extreme Gradient Boosting sobre 138 características en los dominios temporal, frecuencial y cepstral, logrando una precisión del 95,8 %, una sensibilidad del 95,3 % y una especificidad del 96,2 %. De forma parecida, Di Cesare et al. (2024) compararon los resultados de SVM, KNN y redes neuronales con características derivadas de MFCCs y Gammatone Cepstral Coefficients, logrando precisiones de hasta el 92,3 %, con sensibilidad y especificidad equilibradas (75–93 %). Otros estudios, como el de Kar y Campbell (2020), usando un modelo híbrido de regresión logística y red neuronal para detectar Parkinson en fases tempranas, a partir de medidas de Pitch Period Entropy y Spread1, obteniendo valores de sensibilidad del 95–96 % y precisión del 85–96 %.

Para la enfermedad de Alzheimer, García-Gutiérrez et al. (2024) compararon varios algoritmos clásicos (RF, SVM, KNN y Extreme Gradient Boosting) en un conjunto de más de 1500 muestras de voz espontánea, alcanzando puntuaciones F1 entre 84 % y 92 %. En la ELA, Tena et al. aplicaron SVM y Random Forest a componentes cuasi-periódicos de vocales sostenidas, obteniendo precisiones entre 78,7 % y 91,0 % y áreas bajo la curva (AUC) de 0,85–0,99, lo que demuestra la gran capacidad de estos métodos para detectar la afectación bulbar en su etapa inicial.

En conjunto, los métodos clásicos siguen siendo una opción consolidada, sobretudo en los casos donde el tamaño de los datos es limitado y se dispone de features bien definidas. No obstante, su rendimiento suele verse afectado en datasets grandes o con características altamente correlacionadas. En estos los modelos profundos ofrecen ventajas significativas.

2.5.2. Modelos de aprendizaje profundo

El Deep Learning ha transformado todo el campo del aprendizaje automático, incluido el del análisis de voz, permitiendo que los modelos aprendan representaciones directamente, a partir de la señal acústica, reduciendo la tediosa tarea de la extracción manual de características. Entre los

enfoques más frecuentes destacan: las redes neuronales convolucionales (CNN), las redes recurrentes (RNN, LSTM, GRU) y los modelos híbridos CNN-RNN.

En el ámbito del Parkinson, Worasawate et al. (2021) emplearon CNNs (LeNet-5, ResNet-50 y VGG-16), cuyas entradas eran los espectrogramas de vocales sostenidas /aa/ recogidos mediante smartphones. Con un dataset de 4051 muestras, alcanzaron precisiones del 97,7 % al 99,3 %, demostrando la capacidad de las CNN para capturar patrones espacio-temporales en señales ruidosas. Por su parte, Álvarez Marquina et al. (2022) aplicaron CNNs sobre medidas de formantes obtenidas de vocales sostenidas (/a/), obteniendo una precisión del 96 % y especificidad del 99 % en un conjunto de 1280 grabaciones, lo que confirma el potencial de las redes convolucionales para identificar alteraciones articulatorias. Luna-Ortiz et al. (2023), a través de una combinación de análisis dinámico no lineal supervisado y CNNs en dos bases de datos distintas, alcanzando resultados excepcionalmente altos (99,5–99,7 % de precisión). Finalmente, Muntaha et al. (2024) implementaron un modelo atencional híbrido LSTM-BiGRU con un componente de interpretabilidad (Explainable Boosting Machine), obteniendo precisiones entre 96,3 % y 97,5 %.

Los modelos profundos también han mostrado resultados notables en Alzheimer y ELA. Moro-Velázquez et al. (2020, 2021) introdujeron técnicas de x-vectors e i-vectors, integradas en redes neuronales probabilísticas, alcanzando precisiones de 85–94 % y áreas bajo la curva (AUC) de 0,91–0,99 en Parkinson. Aunque su objetivo principal fue la diferenciación de fases clínicas de la enfermedad.

En resumen, los modelos de aprendizaje profundo superan considerablemente a los métodos clásicos en datasets medianos o grandes, gracias a su capacidad para aprender representaciones jerárquicas complejas. Sin embargo, su rendimiento puede verse afectado en muestras pequeñas y requieren un control mayúsculo para evitar sobreajustes teniendo que realizar técnicas de regularización o validación cruzada.

2.5.3. Modelos basados en embeddings y foundation models

En los últimos años, se ha observado una tendencia hacia el uso de modelos auto-supervisados y de representación profunda del habla, capaces de aprender directamente de grandes volúmenes de datos no etiquetados. Estos modelos, denominados foundation models, generan embeddings que condensan información fonética, prosódica y semántica de manera más rica que las features tradicionales.

En el estudio de Alzheimer, Agbavor y Liang (2022) usaron el modelo data2vec junto con clasificadores clásicos (SVM, RF, regresión logística), logrando áreas bajo la curva (AUC) de 0,835–0,846 y evidenciando que los embeddings auto-supervisados pueden sustituir las características manuales desempeñando un excelente papel. En el caso del Parkinson, Dao et al. (2025) exploraron wav2vec 2.0, Whisper y Seamless M4T para extraer representaciones de voz que fueron las entradas de distintos clasificadores. Dicho estudio reporta haber alcanzado un AUC del 91,4 %, confirmando la viabilidad de los foundation models para detectar etapas tempranas de la enfermedad.

El uso de embeddings preentrenados ha demostrado conseguir mejorar la robustez frente a ruido, variabilidad entre hablantes y diferencias de idioma. Además, estos modelos reducen la necesidad de extracción de características y facilitan la transferencia entre tareas, abriendo nuevas posibilidades para la creación de sistemas universales de detección de enfermedades mediante voz.

2.5.4. Inteligencia Artificial explicable (XAI) y modelos interpretables

Un aspecto cada vez más relevante en la aplicación de IA a entornos clínicos es la interpretabilidad de los modelos. Los profesionales de la salud requieren entender qué características vocales influyen en la decisión del modelo para poder validar y confiar en los resultados. Shen et al. (2024) abordaron este desafío aplicando técnicas de Explainable AI a la detección temprana del Parkinson. Su enfoque combinó redes neuronales híbridas (CNN-RNN) con mecanismos de atención y visualización de relevancia, consiguiendo una precisión del 91,1 %, sensibilidad del 92,5 % y especificidad del 89,8 %, al tiempo que identificaban las features más influyentes (MFCCs, jitter, shimmer). De manera complementaria, Muntaha et al. (2024) integraron un componente de Explainable Boosting Machine (EBM) en su arquitectura LSTM-BiGRU, mostrando cómo la atención se concentraba en regiones de la señal asociadas a la disfonía y la falta de control respiratorio.

Estos trabajos marcan una tendencia hacia modelos no solo precisos, sino también transparentes y clínicamente interpretables, condición necesaria para la futura integración de la IA en la práctica médica.

2.5.5. Síntesis Comparativa

El análisis conjunto de los doce estudios revisados permite identificar patrones claros:

- Los **métodos clásicos** (SVM, RF, KNN) siguen siendo competitivos en datasets pequeños o con features bien seleccionadas, con precisiones medias del 80–95 %.
- Las **Redes profundas** (CNN, LSTM) ofrecen los mejores resultados globales (hasta 99 %) en escenarios con grandes volúmenes de datos y tareas controladas.
- Los **Modelos de embeddings y foundation models** representan la evolución natural del campo, destacando por su capacidad de generalización y menor dependencia del preprocesamiento manual.
- Los **enfoques explicables** emergen como una necesidad clave para la validación clínica y la adopción real en entornos sanitarios.

En conclusión, la IA aplicada al análisis de la voz alcanza niveles de rendimiento excepcionales en la detección de enfermedades neurodegenerativas, especialmente en Parkinson y Alzheimer. No

obstante, siguen existiendo desafíos relacionados con la validación cruzada, la variabilidad de los datos y la interpretabilidad de los resultados. La integración de modelos fundacionales con técnicas de XAI se perfila como la línea más prometedora para futuras investigaciones y desarrollos clínicamente aplicables.

2.6. Comparativa de resultados, rendimiento y limitaciones

Para la constitución de este Estado del Arte se ha realizado una revisión bibliográfica de la cual se han seleccionado doce estudios, a partir de los cuales se realiza una síntesis comparativa de resultados, considerando la enfermedad objetivo, el tipo de modelo, las características vocales empleadas y las métricas principales reportadas. La Tabla 1 resume la información más relevante y permite observar tendencias comunes y diferencias metodológicas entre los trabajos.

Nº	Referencia (año)	Enfermedad	Dataset	Modelo(s)	Features / entrada	Métricas clave	Observaciones
1	García-Gutiérrez et al. (2024)	Alzheimer	1500	RF, XGB, SVM, KNN	Paralingüísticas (voz espontánea)	F1: 84–92 %	Enfoque ML clásico; dataset grande
2	Worasawate et al. (2021)	Parkinson	4051	CNN (LeNet, ResNet, VGG)	Espectrogramas /aa/	Acc: 97.7–99.3 %	Grabaciones móviles; dataset extenso
3	Tougui et al. (2020)	Parkinson	1490	SVM, RF, XGB	138 acústicas + cepstrales	Acc: 95.8 %; Sens: 95.3 %	Alto rendimiento con features clásicas
4	Moro-Velázquez et al. (2020–2021)	Parkinson	79–89	GMM-UBM, PLDA	x-/i-vectors, MFCC	Acc: 85–94 %; AUC: 0.91–0.99	Embeddings robustos; validación cruzada
5	Agbavor & Liang (2022)	Alzheimer	237	SVM, RF, LogReg	data2vec embeddings	AUC: 0.835–0.846	Self-supervised learning
6	Dao et al. (2025)	Parkinson	n/d	wav2vec2.0, Whisper, SeamlessM4T	Foundation embeddings	AUC: 91.4 %	Representaciones profundas
7	Muntaha et al. (2024)	Parkinson	n/d	LSTM-BiGRU + EBM	Multisource vocal	Acc: 96.3–97.5 %	Modelo híbrido + XAI
8	Shen et al. (2024)	Parkinson	81	Hybrid CNN-RNN	MFCCs, jitter, shimmer	Acc: 91.1 %; Sens: 92.5 %	Interpretabilidad con XAI
9	Gutz et al. (2019)	ELA	123	SVM	ComParE13 (openSMILE)	AUC: 0.85–0.99	Detección bulbar temprana
10	He et al. (2023)	Alzheimer	119	RF	Acústicas + prosódicas + texto	Acc: >90 %	Enfoque multimodal
11	Álvarez Marquina et al. (2022)	Parkinson	1280	CNN	Formantes (/a/)	Sens: 96 %; Spec: 99 %	Alta especificidad
12	Tena et al. (CMPB)	ELA	n/d	SVM, RF	Quasi-periódicas	Acc: 78.7–91 %	Variabilidad por dataset

Cuadro 2.1: Resumen de los estudios seleccionados sobre detección de enfermedades neurodegenerativas mediante análisis de voz.

Como se observa en la tabla ??, los estudios centrados en la enfermedad de Parkinson son los más abundantes y alcanzan los mayores niveles de precisión (97–99 %), especialmente cuando se utilizan modelos profundos basados en espectrogramas o embeddings. En Alzheimer, los resultados se sitúan entre 84 % y 92 %, destacando el uso de características paralingüísticas y modelos auto-supervisados, mientras que en ELA las métricas, varían entre 78 % y 99 %, dependiendo del conjunto de datos. Estas cifras, aunque elevadas, deben interpretarse con cuidado debido a la variedad de métodos usados entre los estudios.

2.6.1. Resultados por enfermedades

Parkinson

Es la enfermedad más estudiada y aquella donde se han alcanzado los rendimientos más altos. Las precisiones varían entre 85 % y 99 %, con áreas bajo la curva (AUC) cercanas a 0.99 en los estudios de Moro-Velázquez et al. (2020, 2021) y Worasawate et al. (2021). Los modelos basados en CNN y embeddings ofrecen mejor desempeño en bases de datos grandes, mientras que los métodos clásicos (SVM, RF) continúan mostrando eficacia en muestras pequeñas o con características cuidadosamente seleccionadas. La variabilidad en las tareas vocales y la calidad del audio tienen una influencia directa en las métricas obtenidas.

Alzheimer

Los estudios de Alzheimer presentan resultados sólidos aunque algo más moderados. García-Gutiérrez et al. (2024) lograron valores F1 entre 84 % y 92 % con algoritmos clásicos, mientras que Agbavor y Liang (2022) obtuvieron AUC de 0.835–0.846, utilizando embeddings auto-supervisados (data2vec). En general, los modelos que integran información de voz y texto, como el de He et al. (2023), muestran un mejor rendimiento al capturar tanto alteraciones acústicas como lingüísticas.

Esclerosis Lateral Amiotrófica (ELA)

En el caso de la ELA, los estudios son menos numerosos pero prometedores. Gutz et al. (2019) alcanzaron AUC de 0.85–0.99 utilizando SVM con features ComParE13, mientras que Tena et al. reportaron precisiones de 78–91 %, según el subconjunto analizado. La detección de la afectación bulbar a partir de la voz demuestra una aplicabilidad clínica potencial, aunque la limitada disponibilidad de datos sigue siendo un obstáculo importante.

2.6.2. Limitaciones de los estudios

A pesar de los buenos resultados obtenidos, la literatura revisada comparte una serie de limitaciones comunes que reflejan los desafíos actuales del uso de la voz y la IA en el diagnóstico de enfermedades neurodegenerativas.

a) Escasez y heterogeneidad de los datos

Los tamaños muestrales varían desde unas decenas hasta varios miles de grabaciones, con diferencias notables en idioma, edad y calidad de audio. Esta falta de estandarización impide la comparación directa y reduce la capacidad de generalización de los modelos.

b) Diversidad de tareas vocales y condiciones de grabación

Cada estudio utiliza protocolos distintos (vocales sostenidas, lectura o discurso espontáneo), lo que condiciona los biomarcadores detectables. Además, la variabilidad en los dispositivos de grabación —desde micrófonos profesionales hasta smartphones— introduce ruido y afecta la fiabilidad de los resultados.

c) Validación interna y riesgo de sobreajuste

La mayoría de los trabajos aplican validaciones cruzadas internas (k-fold, Leave-One-Out), sin evaluar los modelos sobre conjuntos de prueba independientes. Esto puede inflar las métricas de precisión y ocultar problemas de sobreajuste, especialmente en redes profundas con pocos datos.

d) Métricas inconsistentes y ausencia de intervalos de confianza

Los estudios reportan diferentes métricas (accuracy, F1, AUC, sensibilidad, especificidad), dificultando la comparación objetiva. En general, los valores son altos, pero rara vez se acompañan de intervalos de confianza o análisis estadísticos que permitan valorar su significación.

e) Falta de interpretabilidad

La mayoría de los modelos profundos actúan como “cajas negras”. Solo algunos estudios recientes (Shen et al., 2024; Muntaha et al., 2024) han incorporado técnicas de Explainable AI (XAI) que

permiten identificar qué features vocales influyen en la decisión del modelo. La interpretabilidad sigue siendo clave para su aceptación clínica

En conjunto, estas limitaciones muestran un campo todavía en construcción. La combinación de datasets pequeños, falta de estandarización y escasa validación hace que los valores de precisión reportados deban interpretarse como una estimación potencial más que como resultados clínicamente generalizables.

2.6.3. Conclusiones

La comparación de los doce estudios revisados permite identificar un patrón claro: los modelos de aprendizaje profundo y de embeddings son los más eficaces en la detección de alteraciones vocales asociadas a enfermedades neurodegenerativas, alcanzando precisiones de hasta el 99 % en Parkinson y AUC superiores al 0.9 en Alzheimer y ELA. Sin embargo, el progreso del campo depende de superar desafíos estructurales como la falta de datos estandarizados, la validación clínica limitada y la necesidad de modelos más explicables.

En resumen, la evidencia actual demuestra el enorme potencial de la voz como biomarcador y de la IA como herramienta diagnóstica, y subraya la importancia de avanzar hacia protocolos uniformes, bases de datos abiertas, evaluaciones externas y modelos transparentes que permitan trasladar estos avances al ámbito médico real.

2.7. Tendencias y líneas futuras

El análisis de los estudios revisados pone sobre la mesa que la Inteligencia Artificial aplicada al análisis de la voz para la detección temprana de enfermedades neurodegenerativas es un campo en expansión, con resultados prometedores pero que aún está en una fase experimental. A partir de las evidencias recopiladas, pueden observarse varias tendencias tecnológicas y líneas de investigación futura que marcan el paso de la evolución de esta disciplina.

2.7.1. Avances en modelos de representación y foundation models

Una de las líneas más claras es la transición desde modelos basados en features manuales hacia representaciones profundas aprendidas automáticamente. Los estudios más recientes (Agbavor & Liang, 2022; Dao et al., 2025) demuestran el potencial de los modelos auto-supervisados como: data2vec, wav2vec2.0 o Whisper, capaces de aprender representaciones acústicas sin necesidad de anotaciones. Estos foundation models permiten procesar grandes volúmenes de datos no etiquetados y facilitan la transferencia entre tareas, reduciendo la dependencia de datasets específicos. En el futuro, el uso de

estos modelos preentrenados mejorará la generalización, acelerará el desarrollo de nuevos sistemas y sentará las bases para herramientas diagnósticas basadas en voz.

2.7.1.1. Integración multimodal de datos

Varios estudios coinciden en la necesidad de combinar información acústica, prosódica, lingüística y textual para mejorar la precisión diagnóstica, especialmente en enfermedades donde los síntomas cognitivos son más marcados, como el Alzheimer (García-Gutiérrez et al., 2024; He et al., 2023). El análisis conjunto de voz y texto, o de voz y datos clínicos complementarios, constituye una tendencia ascendente hacia modelos multimodales capaces de reflejar de forma más completa los cambios neurológicos. La fusión de estas fuentes de información permitirá desarrollar sistemas más robustos y sensibles a las distintas manifestaciones de la enfermedad.

2.7.1.2. Explicabilidad y validación clínica

Los avances técnicos deben ir acompañados de una mayor transparencia e interpretabilidad de los modelos. Las aproximaciones recientes que incorporan Explainable AI (Shen et al., 2024; Muntaha et al., 2024) enseñan que es posible identificar qué características vocales influyentes en la clasificación, lo que facilita la validación por parte de especialistas. En un futuro próximo se espera un incremento de los trabajos centrados en IA explicable y validada clínicamente, condición necesaria para la incorporación de estos sistemas en entornos sanitarios. La colaboración entre ingenieros, lingüistas y médicos será la clave para traducir los resultados de laboratorio en herramientas diagnósticas reales.

2.7.1.3. Creación de bases de datos abiertas y estandarizadas

La falta de datasets grandes y uniformes es una de las principales barreras actuales. La tendencia internacional apunta hacia la construcción de bases de datos abiertas, multilingües y balanceadas, que permitan comparar modelos bajo las mismas condiciones experimentales. Iniciativas de este tipo facilitarían la reproducibilidad de los resultados y el desarrollo de modelos robustos y equitativos. Además, la estandarización de protocolos de grabación y tareas vocales (vocales sostenidas, lectura, discurso libre) será esencial para reducir la variabilidad y establecer puntos de referencia comunes en la comunidad científica.

2.7.1.4. Aplicaciones en entornos reales y monitorización continua

Los avances en hardware y en conectividad han abierto la posibilidad de aplicar estos sistemas fuera del laboratorio. Estudios como el de Worasawate et al. (2021) muestran la viabilidad de utilizar

grabaciones obtenidas con smartphones para detectar alteraciones vocales, por lo que se prevee un futuro donde las herramientas de cribado puedan implementarse en dispositivos de uso cotidiano. La tendencia apunta hacia la monitorización continua y remota, permitiendo un seguimiento no invasivo y económico, así como la detección temprana de recaídas o empeoramientos.

2.7.1.5. Síntesis prospectiva

En conjunto, las líneas futuras del campo pueden resumirse en cinco ejes principales:

- **Automatización y auto-supervisión**, adoptando foundation models para extraer representaciones generales del habla.
- **Multimodalidad**, realizando la fusión de la voz, texto y otros datos clínicos.
- **Explicabilidad**, llevando a cabo una incorporación sistemática de técnicas XAI para aumentar la confianza clínica.
- **Estandarización de datos**, creando datasets abiertos, equilibrados y comparables.
- **Aplicación práctica**, implementando plataformas móviles y entornos reales para monitorización temprana.

Estas tendencias apuntan hacia un mundo donde la voz se asienta como un biomarcador accesible y fiable, y donde la Inteligencia Artificial, combinada con una validación clínica, permite el desarrollo de sistemas de detección precoz con impacto real en la práctica médica.

2.8. Conclusiones

La revisión realizada deja constancia del notable avance de la Inteligencia Artificial aplicada al análisis de la voz como herramienta para la detección temprana de enfermedades neurodegenerativas. Los doce estudios analizados muestran que la voz contiene información acústica, prosódica y articulatoria capaz de reflejar alteraciones motoras y cognitivas propias de patologías como el Parkinson, el Alzheimer o la Esclerosis Lateral Amiotrófica (ELA).

Los resultados obtenidos por los diferentes modelos, con precisiones que en algunos casos superan el 95 %, confirman que la voz promete ser un biomarcador no invasivo, económico y de fácil acceso. Los métodos de Machine Learning clásico han demostrado su eficacia en datasets pequeños y con features cuidadosamente seleccionadas, mientras que las redes neuronales profundas y los foundation models ofrecen una capacidad superior de generalización y aprendizaje de patrones complejos directamente desde la señal acústica.

Sin embargo, el campo se encuentra todavía en una fase de crecimiento. Siguen existiendo limitaciones significativas, como la falta de bases de datos públicas, amplias y estandarizadas, la nula validación clínica externa, la variabilidad en las tareas de grabación y la necesidad de modelos más interpretables. Abordar estos desafíos será un hito para garantizar la fiabilidad y aplicabilidad de los sistemas desarrollados.

Las tendencias actuales sugieren un camino hacia la adopción de modelos auto-supervisados, la integración multimodal de voz y texto, el desarrollo de técnicas de Explainable AI y la creación de repositorios abiertos que fomenten la reproducibilidad. En conjunto, estas líneas futuras configuran un horizonte prometedor, donde la colaboración entre ingeniería, lingüística y medicina permitirá que la IA basada en la voz evolucione desde el laboratorio hacia su uso clínico real como herramienta de diagnóstico y monitorización temprana de enfermedades neurodegenerativas.

Metodología y Entorno de Trabajo

3.1. Descripción de los Datasets y Modalidades Acústicas

Para el desarrollo de este proyecto se han utilizado dos datasets. A continuación pasamos a realizar un análisis exploratorio de cada uno de los conjuntos de datos para entender mejor su composición.

3.1.1. Dataset 1: NeuroVoz

El primero es un corpus de habla hispana denominado NeuroVoz, este conjunto de datos pionero recoge las grabaciones de 108 participantes españoles repartidos en dos grupos, el primero compuesto por 53 individuos diagnosticados positivamente con Parkinson, y el segundo de los grupos compuesto por 55 controles sanos. En lo que es relativo a los enfermos con Parkinson es importante reseñar que todos están bajo los efectos de medicación, lo que asegura la consistencia del dataset.

Dentro del conjunto de audios, podemos encontrar varias actividades vocales como pueden ser la fonación de vocales sostenidas, ejercicios de habla espontánea, prácticas de repetición y pruebas diacocinéticas(TDDK). Esta últimas, son palabras inventadas perfectamente diseñadas para observar la capacidad del sistema nervioso para realizar movimientos motores alternantes y rápidos (?, ?)

3.1.2. Dataset 2: PC-GITA

Dataset 2: Audios de habla continua (frases)

3.2. Preprocesamiento de datos

3.2.1. Preprocesamiento de los audios

Preprocesamiento de los audios

3.2.2. Extracción de características manuales para ML

3.2.2.1. Extracción de características

Extracción de características

3.2.2.2. Selección de características

Selección de características

3.2.3. Generación de espectrogramas para Deep Learning

Generación de espectrogramas para Deep Learning

3.3. Entorno tecnológico (Hardware, librerías de Python)

3.3.1. Hardware utilizado

Para el desarrollo de este proyecto se ha hecho uso del ordenador personal del alumno cuyas especificaciones son las que a continuación se detallan:

3.3.2. Librerías de Python utilizadas

Para el desarrollo de este proyecto se ha establecido un entorno de trabajo basado en Python. La gestión de los paquetes y las dependencias se ha realizado utilizando **uv**, un gestor de proyectos

Componente	Especificación
Procesador (CPU)	Intel® Core™ i7-12650H (10 núcleos, 16 subprocesos) 2.30 GHz
Memoria RAM	16 GB SODIMM a 3200 MT/s
Tarjeta Gráfica (GPU)	NVIDIA® GeForce® RTX™ 3050 Laptop GPU (4 GB VRAM)
Almacenamiento	512 GB SSD (WD PC SN740)
Sistema Operativo	Windows 11 Pro (64 bits)

Cuadro 3.1: Especificaciones de hardware del equipo portátil utilizado para el entrenamiento de los modelos.

moderno escrito en Rust que destaca por su extrema rapidez y su capacidad para garantizar la reproducibilidad de los experimentos.

Debido a la gran cantidad de librerías involucradas en el entrenamiento de los modelos y el despliegue del sistema, en la ?? se resumen las herramientas principales, agrupadas según su propósito dentro del flujo de trabajo.

Librería / Herramienta	Propósito en el proyecto
Gestión de Entorno y Backend	
uv	Gestor de paquetes y dependencias ultrarrápido escrito en Rust.
FastAPI & Uvicorn	Desarrollo y despliegue del servidor API REST.
Deep Learning y Machine Learning	
Ecosistema PyTorch	Framework principal (incluye TorchAudio y TorchVision).
Transformers & TIMM	Implementación de modelos de lenguaje y visión avanzados.
XGBoost & scikit-learn	Algoritmos de aprendizaje automático tradicional y métricas.
SHAP	Explicabilidad e interpretabilidad de los modelos de IA.
Procesamiento de Audio y Datos	
Librosa, Parselmouth & NoiseReduce	Carga, limpieza y extracción de características acústicas.
Pandas, NumPy & SciPy	Manipulación de datos tabulares y cálculo científico.
Matplotlib & Seaborn	Visualización de datos y generación de gráficas.

Cuadro 3.2: Principales librerías y herramientas de software utilizadas en el proyecto agrupadas por categoría.

Como se puede observar, el núcleo del proyecto se apoya fuertemente en el ecosistema de PyTorch para el aprendizaje profundo, complementado con FastAPI para la creación de la interfaz de comunicación.

Para mantener la claridad del documento, el listado exhaustivo y completo de todas las dependencias del proyecto, junto con sus versiones exactas y subdependencias (reflejadas en el entorno virtual generado por uv), se encuentra detallado en el .

3.4. Métricas de evaluación

Métricas de evaluación (Recall, F1-Score, etc.)

Diseño y Desarrollo de los Modelos

4.1. Configuración experimental y estrategias de entrenamiento

Configuración experimental y estrategias de entrenamiento (validación cruzada, optimización de hiperparámetros, etc.).

4.2. Machine Learning tradicional: KNN y XGBoost

4.2.1. KNN

KNN

4.2.2. XGBoost

XGBoost

4.3. Deep Learning basado en imágenes: Arquitectura ResNet18

Deep Learning basado en imágenes: Arquitectura ResNet18

4.4. Foundation Models: Extracción de características con Whisper + Clasificación

Foundation Models: Extracción de características con Whisper + Clasificación

4.5. Modelo End-to-End mediante Fine-Tuning de Whisper

Modelo End-to-End mediante Fine-Tuning de Whisper

Prueba de Concepto: Aplicación Interactiva de Diagnóstico

5.1. Arquitectura del sistema

5.1.1. Frontend móvil/web con Flutter

Frontend móvil/web con Flutter

5.1.2. API REST Backend con FastAPI

API REST Backend con FastAPI

5.2. Flujo de datos y diagrama de secuencia de la predicción

Flujo de datos y diagrama de secuencia de la predicción

5.3. Despliegue del modelo XGBoost y generación de explicabilidad (SHAP)

Despliegue del modelo XGBoost y generación de explicabilidad (SHAP)

5.4. Interfaz de usuario: Análisis de resultados

Interfaz de usuario: Análisis de resultados

Resultados y Discusión

6.1. Comparativa de rendimiento según la modalidad del dato (Vocales vs. Frases vs. Fusión)

Comparativa de rendimiento según la modalidad del dato (Vocales vs. Frases vs. Fusión)

6.2. Comparativa arquitectónica (Modelos Clásicos vs. ResNet18 vs. Whisper)

Comparativa arquitectónica (Modelos Clásicos vs. ResNet18 vs. Whisper)

6.3. Análisis de interpretabilidad clínica mediante valores SHAP

Análisis de interpretabilidad clínica mediante valores SHAP (Justificación de decisiones del XG-Boost)

6.4. Discusión global: Precisión frente a coste computacional e interpretabilidad

Discusión global: Precisión frente a coste computacional e interpretabilidad

Conclusiones y Trabajo Futuro

7.1. Conclusiones y grado de consecución de los objetivos

Conclusiones y grado de consecución de los objetivos

7.2. Limitaciones del estudio

Limitaciones del estudio

7.3. Líneas de trabajo futuro

Líneas de trabajo futuro

Dependencias del entorno virtual

En este anexo se detalla la configuración exacta del entorno de software utilizado para el desarrollo, entrenamiento y despliegue de los modelos de inteligencia artificial del proyecto. La gestión del entorno se ha llevado a cabo mediante el gestor de dependencias `uv`.

Entorno base

- **Lenguaje principal:** Python 3.11.14
- **Gestor de paquetes:** `uv`

Listado de librerías

A continuación, se expone el listado exhaustivo de las dependencias principales requeridas para la correcta ejecución del código fuente, tal y como se especificarían en el archivo de configuración del proyecto:

```
fastapi>=0.135.1
ipykernel>=7.2.0
joblib>=1.5.3
jupyter>=1.1.1
librosa>=0.11.0
matplotlib>=3.10.8
noisereduce>=3.0.3
numpy>=2.4.2
pandas>=3.0.1
praat-parselmouth>=0.4.7
python-multipart>=0.0.22
scikit-learn>=1.8.0
scipy>=1.17.0
```

```
seaborn>=0.13.2
shap>=0.49.1
timm>=1.0.25
torch>=2.6.0
torchvision>=0.20.0
torchaudio>=2.6.0
tqdm>=4.67.3
uvicorn>=0.41.0
xgboost==2.0.3
openpyxl>=3.1.5
transformers>=5.7.0
```